Institut Supérieur d'Informatique et de Mathématiques de Monastir

Module : Traitement de Données

Détection des émotions dans les textes en langue arabe

Rapport de la phase 1 (CRISP-DM)

Compréhension du métier, collecte, compréhension et préparation des données

Réalisé par

Mohamed Yassine Kaibi
Chanaz Jammoussi
Anes Selmi

Encadré par

Mme Mariem Gzara

Année universitaire 2026/2027

Résumé

Ce rapport couvre la première phase de notre projet, menée selon la méthode CRISP-DM : compréhension du métier, collecte, compréhension et préparation des données. Le sujet traité est la détection automatique de l'émotion exprimée par un texte arabe. Nous avons construit un corpus de 15 665 textes étiquetés selon sept émotions (joie, tristesse, amour, colère, peur, surprise, neutre), en intégrant trois jeux de données publics de registres différents : des poèmes classiques, des tweets en dialecte égyptien et des tweets multi-dialectes issus de SemEval-2018. L'exploration a mis en évidence plusieurs biais que la phase de modélisation devra contrôler : les émotions sont liées à la source (aucun poème n'exprime la colère), 98,5 % des tweets neutres d'ETDA portent sur les Jeux olympiques de 2016, et les mots les plus caractéristiques de la colère sont des noms propres et des entités politiques. Le pipeline de préparation est entièrement reproductible : un script télécharge les sources, les nettoie, harmonise les étiquettes et produit le corpus, les rapports de qualité et les figures.

Table des matières

1 Introduction **3**

2 Compréhension du métier **3**
2.1 Problème à résoudre . . . 3
2.2 Contexte métier et applications . . . 3
2.3 Pourquoi l'apprentissage automatique et la fouille de données . . . 4
2.4 Périmètre du sujet . . . 4
2.5 Objectifs et critères de succès . . . 4
2.6 Risques . . . 5
2.7 Plan du projet . . . 5

3 État de l'art **6**
3.1 Jeux de données arabes pour les émotions . . . 6
3.2 Modèles de langue arabes . . . 7
3.3 Résultats de référence . . . 7
3.4 Lecture critique d'ArabSis . . . 7

4 Collecte des données **8**
4.1 Sources retenues . . . 8
4.2 Pourquoi intégrer plusieurs sources . . . 8
4.3 Sources écartées . . . 9
4.4 Outils et procédure de collecte . . . 9

5 Compréhension des données **10**
5.1 Description . . . 10
5.2 Exploration . . . 11
5.3 Qualité des données . . . 12

6 Préparation des données **13**
6.1 Nettoyage . . . 13
6.2 Transformation . . . 14
6.3 Intégration . . . 15
6.4 Enrichissement . . . 16
6.5 Bilan de la préparation . . . 17

7 Limites et suite du projet **17**
7.1 Limites connues . . . 17
7.2 Décisions reportées à la phase 2 . . . 18

A Organisation du code et reproduction **19**

B Schéma du corpus **19**

1 Introduction

La reconnaissance des émotions dans les textes cherche à identifier l'état affectif exprimé par un auteur : joie, tristesse, colère, peur, etc. La plupart des ressources et des modèles existants portent sur l'anglais. L'arabe, parlé par environ 420 millions de personnes selon Shahriar et al. [11], reste moins couvert, et cette couverture est fragmentée entre l'arabe classique, l'arabe standard moderne (MSA) et des dialectes régionaux qui diffèrent fortement entre eux.

Le projet du module Traitement de Données suit la méthode CRISP-DM [7], qui découpe un projet de fouille de données en six étapes : compréhension du métier, compréhension des données, préparation des données, modélisation, évaluation et déploiement. Ce rapport couvre les étapes de la première phase du calendrier du module :

- la compréhension du métier : problème, contexte, intérêt de l'apprentissage automatique, objectifs et plan (section 2) ;
- la collecte des données : sources, données brutes et outils de collecte (section 4) ;
- la compréhension des données : description, exploration et qualité (section 5) ;
- la préparation des données : nettoyage, transformation, intégration et enrichissement (section 6).

La section 3 résume les travaux et les jeux de données qui ont guidé nos choix, et la section 7 présente les limites connues et les décisions reportées à la phase 2.

Tous les chiffres de ce rapport sont produits par le code du projet (fichiers `reports/quality_report.json` et `reports/eda_stats.json`), et non saisis à la main. L'annexe A décrit l'organisation du code et la commande qui régénère les données, les chiffres et les figures.

2 Compréhension du métier

2.1 Problème à résoudre

Étant donné un texte arabe, le système doit prédire l'émotion qu'il exprime parmi sept classes : joie, tristesse, amour, colère, peur, surprise et neutre. Il s'agit d'une classification supervisée multiclasse, à une seule étiquette par texte.

La difficulté principale vient de la variété des textes. Un même modèle doit traiter de la poésie classique, écrite dans une langue littéraire, souvent vocalisée et riche en images, et des tweets courts en dialecte égyptien ou en dialectes du Golfe, du Levant ou du Maghreb, avec leur orthographe libre, leurs émojis et leurs hashtags. Le problème comporte donc deux questions : prédire l'émotion, et vérifier que la prédiction repose sur des indices émotionnels plutôt que sur le registre ou le thème du texte.

2.2 Contexte métier et applications

L'analyse de sentiment classique, qui sépare les textes positifs, négatifs et neutres, ne suffit pas pour plusieurs usages. Une réaction négative peut être de la colère, de la peur ou de la tristesse, et chacune appelle une réponse différente. Nous retenons trois domaines d'application :

- **Veille des réseaux sociaux et des marques** sur les marchés arabophones : suivre les réactions émotionnelles à un événement, une campagne ou un produit, au-delà de la polarité.
- **Patrimoine numérique et enseignement** : étiqueter des poèmes par émotion pour la recherche, la recommandation et l'enseignement de la littérature arabe. Le site aldiwan.net, d'où proviennent nos poèmes, classe déjà ses textes par catégorie, mais à la main.
- **Analyse de l'opinion publique** : mesurer les réactions aux actualités et aux décisions politiques. Nos données montrent d'ailleurs que la colère est fortement associée à des sujets

politiques (section 5.3), ce qui illustre à la fois l'intérêt de l'application et le risque d'un modèle qui apprendrait le thème au lieu de l'émotion.

2.3 Pourquoi l'apprentissage automatique et la fouille de données

Une première approche consisterait à utiliser un lexique : une liste de mots associés à chaque émotion. Nos données montrent pourquoi cette approche échoue sur l'arabe :

- **Morphologie.** Après normalisation, le corpus contient 159 246 formes de mots distinctes, parce que les clitiques restent attachés aux mots (ولم, بالحب). Un lexique devrait prévoir chaque forme fléchie et préfixée.
- **Dialectes.** Les marqueurs dialectaux comme ازاي (comment), دا (ceci) ou كدا (ainsi) n'appartiennent à aucun lexique de l'arabe standard.
- **Langue figurée.** La poésie classique exprime le chagrin par l'image (les larmes, la tombe, la séparation) plus que par des mots d'émotion explicites.
- **Négation et contexte.** « Je ne suis pas content » contient un mot de joie. Seul un modèle qui tient compte du contexte peut traiter ces cas.

Un modèle appris sur des textes étiquetés tient compte du contexte et des combinaisons de mots. La fouille de données joue un second rôle : l'exploration du corpus révèle des régularités cachées, comme le lien entre les tweets neutres et les Jeux olympiques, qu'aucune règle écrite à la main n'aurait anticipées et qu'un modèle exploiterait sans le dire.

Enfin, trois jeux de données arabes déjà étiquetés existent pour cette tâche. L'apprentissage supervisé est donc possible sans annotation manuelle, que l'équipe n'avait pas le temps de réaliser.

2.4 Périmètre du sujet

Le sujet 4 est intitulé « Détection des émotions dans les textes en langues arabes » et propose trois axes : (1) la détection des personnes dépressives, (2) la détection des personnes fragiles émotionnellement et (3) la variation des émotions en fonction d'un critère à définir.

Nous traitons la détection générale des émotions et l'axe (3), que nous définissons comme la **variation des émotions selon le registre et la variété d'arabe** : poésie classique, tweets égyptiens, tweets multi-dialectes. Chaque texte du corpus porte ces deux attributs, ce qui permettra de comparer la distribution des émotions et les performances du modèle d'un registre à l'autre.

Les axes (1) et (2) demandent une étiquette au niveau de la *personne* (un diagnostic, un historique de publications, un état psychologique), et non au niveau du texte. Aucun jeu de données arabe public ne fournit ce type d'étiquette. Ces axes posent aussi des questions éthiques importantes : un modèle qui qualifie une personne de dépressive à partir de ses messages engage sa responsabilité bien plus qu'un modèle qui étiquette un tweet. Nous les laissons donc hors du périmètre.

2.5 Objectifs et critères de succès

Nous distinguons les objectifs métier, formulés pour un utilisateur, et les objectifs de fouille de données, formulés en termes mesurables.

Objectifs métier.

- Fournir des étiquettes d'émotion utilisables sur des tweets et des poèmes jamais vus.
- Accompagner chaque prédiction d'une explication (les mots qui ont le plus pesé) qu'un non-spécialiste peut vérifier.
- Décrire comment la distribution des émotions varie selon le registre et le dialecte (axe 3).

Objectifs de fouille de données.

- Construire un corpus harmonisé, nettoyé et documenté à partir de plusieurs sources (objet de ce rapport).
- Dépasser deux références en macro-F1 : la classe majoritaire et une régression logistique sur TF-IDF.
- Rapporter les scores par source, à côté des résultats publiés pour chaque jeu de données (tableau 3), en précisant qu'ils ne sont pas directement comparables.
- Mesurer l'ampleur des raccourcis liés à la source et au thème (section 5.3).

Critère de succès chiffré. La métrique principale est le macro-F1, qui donne le même poids à chaque classe malgré le déséquilibre du corpus (la plus grande classe est 3,45 fois plus grande que la plus petite). Le classifieur qui prédit toujours la classe majoritaire (tristesse, 3 624 textes sur 15 665) obtient une exactitude de 23,1 % mais un macro-F1 de seulement 0,054. Ce chiffre est le plancher. Le seuil de la régression logistique sur TF-IDF sera mesuré en phase 3 ; nous préférons ne pas fixer de cible arbitraire avant de connaître cette référence.

2.6 Risques

Le tableau 1 recense les risques identifiés pendant la collecte et l'exploration, et la réponse prévue pour chacun.

Tab. 1 : Risques du projet et mesures prévues.

Risque	Description	Mesure
Raccourci lié à la source	Les étiquettes dépendent du registre : aucun poème n'exprime la colère, la peur, la surprise ou la neutralité.	Plafond de 50 % de poèmes par émotion, scores par source, classifieur de source, évaluation en excluant une source.
Fuite thématique	98,5 % des tweets neutres d'ETDA portent sur les Jeux olympiques de Rio.	Entraînement sans ces tweets et comparaison du rappel de la classe neutre.
Bruit d'étiquetage	Trois schémas d'annotation différents sont harmonisés.	Table de correspondance documentée, classe « sympathy » retirée, textes contradictoires supprimés.
Déséquilibre des classes	Rapport de 3,45 entre la plus grande et la plus petite classe.	Macro-F1 comme métrique principale, pondération des classes.
Couverture	Pas de dialecte maghrébin, pas de texte journalistique.	Limite déclarée dans les conclusions.
Licences	Les conditions de SemEval interdisent la redistribution.	Scripts de téléchargement uniquement, données exclues du dépôt Git.

2.7 Plan du projet

Le calendrier suit les phases fixées pour le module (figure 1). Le tableau 2 détaille le contenu prévu pour chaque phase.

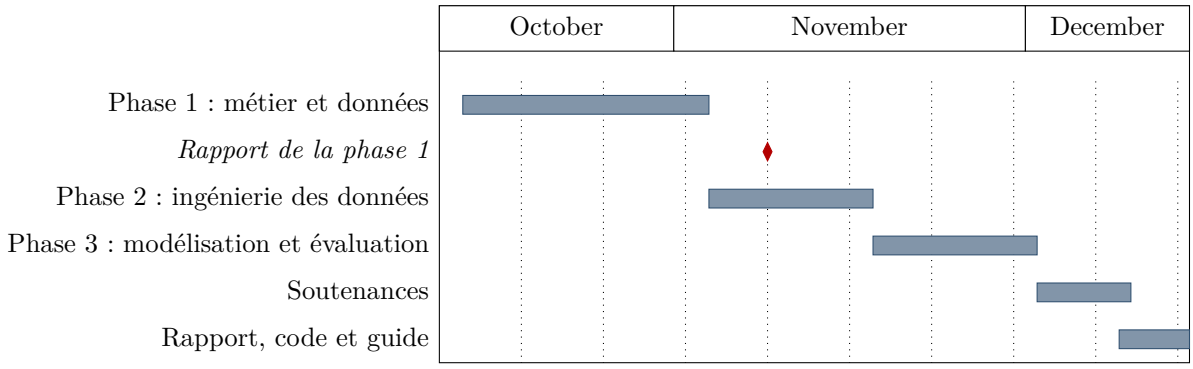


Fig. 1 : Calendrier du projet.

Tab. 2 : Contenu prévu par phase.

Phase	Travaux
1. Métier et données	Définition du problème, collecte de trois sources, exploration, contrôle de qualité, nettoyage, normalisation, harmonisation des étiquettes.
2. Ingénierie des données	Découpage stratifié par émotion et par source (70/15/15, graine fixe) ; segmentation morphologique ou racinisation ; représentations TF-IDF (mots et caractères) et tokenisation des transformeurs ; traitement des poèmes longs ; contrôle des fuites (hashtags, Jeux olympiques, émojis).
3. Modélisation et évaluation	Références (classe majoritaire, régression logistique, SVM linéaire, Naive Bayes) ; ajustement fin de CAMeLBERT-Mix et MARBERT ; macro-F1 global et par source ; tests de raccourcis ; explicabilité (coefficients, LIME ou SHAP) ; analyse de l'axe 3.
4. Restitution	Démonstration interactive (saisie d'un texte, émotion prédite, mots déterminants), soutenance de 15 minutes, rapport final, code et guide d'utilisation.

Ressources. Python 3.10 et les bibliothèques pandas, NumPy, NLTK et matplotlib pour la phase 1 ; scikit-learn et Hugging Face Transformers pour les phases suivantes. L'entraînement des transformeurs sera réalisé sur un GPU Google Colab, faute de GPU local. Le code est versionné sur GitHub.

3 État de l'art

3.1 Jeux de données arabes pour les émotions

Shahriar et al. [11] ont construit le jeu de poèmes que nous utilisons : 9 452 poèmes extraits du site aldiwan.net, seul site qui regroupait les poèmes par émotion. La classe « triste » réunit les catégories tristesse et élégie (رثاء) du site, et la classe « amour » ses poèmes romantiques. Leur meilleur modèle, AraBERT, atteint 76,5 % d'exactitude et un F1 de 0,77, sur un seul découpage 80/20 sans validation croisée.

Al-Khatib and El-Beltagy [2] ont publié ETDA (Emotional Tone Dataset), 10 065 tweets en dialecte égyptien répartis en huit classes. Le meilleur résultat annoncé dans leur dépôt est une exactitude de 68,12 % avec un Naive Bayes complémentaire.

Mohammad et al. [10] ont organisé la tâche 1 de SemEval-2018, « Affect in Tweets », dont la sous-tâche E-c propose 4 381 tweets arabes annotés en multi-étiquettes selon onze émotions. Chaque tweet a été annoté par plusieurs personnes recrutées dans des pays arabes, et une émotion est retenue dès que plus de 25 % des annotateurs la choisissent. Le meilleur système arabe obtient un indice de Jaccard de 48,9 et un macro-F1 de 46,1.

D'autres ressources existent mais n'étaient pas utilisables. ArPanEmo [4] contient 11 128 messages saoudiens sur la COVID-19, mais sa version publique est incomplète (section 4.3). Aljuhani et al. [3] travaillent sur la parole, avec 175 enregistrements en dialecte saoudien ; leur meilleur score (77,14 %) correspond à 27 extraits correctement classés sur 35. Ces deux exemples montrent à quel point les ressources arabes sont petites et dispersées.

3.2 Modèles de langue arabes

Trois familles de modèles pré-entraînés serviront en phase 3 :

- **AraBERT** [5], entraîné sur environ 24 Go de textes en arabe standard (presse, Wikipédia). Il convient au registre littéraire, moins aux dialectes.
- **CAMeLBERT** [9], décliné en variantes arabe standard, dialectale, classique et mixte. Les auteurs montrent que la proximité entre la variété de pré-entraînement et celle de la tâche compte davantage que la taille du corpus. Notre corpus mélangeant poésie classique et tweets dialectaux, la variante mixte est un candidat naturel.
- **MARBERT** [1], entraîné sur un milliard de tweets arabes, majoritairement dialectaux. Il convient aux deux sources de tweets.

3.3 Résultats de référence

Le tableau 3 rassemble les meilleurs résultats publiés sur chacune de nos sources. Aucun n'est directement comparable à notre tâche à sept classes : ils donnent un ordre de grandeur par source.

Tab. 3 : Meilleurs résultats publiés sur nos sources.

Données	Tâche	Meilleur résultat	Source
Poèmes (3 classes)	Multiclasse	AraBERT : exactitude 76,5 %, F1 0,77	Shahriar et al. [11]
ETDA (8 classes)	Multiclasse	Naive Bayes complémentaire : exactitude 68,12 %	Al-Khatib and El-Beltagy [2]
SemEval E-c arabe (11 émotions)	Multi-étiquette	Jaccard 48,9, macro-F1 46,1	Mohammad et al. [10]

3.4 Lecture critique d'ArabSis

ArabSis [8] propose 701 phrases en arabe standard tirées de la littérature, étiquetées selon cinq émotions puis augmentées à 3 505 phrases, avec une exactitude annoncée de 98,6 %. L'article soutient que les corpus de tweets dialectaux ne conviennent pas aux textes littéraires, ce qui justifie notre choix d'inclure une source poétique, et son prétraitement (suppression des diacritiques, normalisation des lettres, mots vides de NLTK) est proche du nôtre. Trois points invitent cependant à la prudence :

1. L'augmentation semble réalisée avant le découpage 80/20 : des quasi-copies des phrases de test se retrouvent alors dans l'apprentissage. Un arbre de décision atteint une exactitude de 1,000 sur la classe Liking.
2. Dans le tableau 6 de l'article, plusieurs modèles (LSTM, CNN, Naive Bayes de Bernoulli) ont un rappel de 1,000, une exactitude égale à la proportion de la classe et une AUC proche de 0,5 : ils prédisent une seule classe pour tous les exemples.
3. Tous les résultats sont binaires (une émotion contre les autres) sur des sous-ensembles équilibrés, et ne se comparent pas à une classification multiclasse.

Ces observations ont orienté notre méthode : découpage avant toute transformation des données, scores rapportés par classe et références simples pour détecter un modèle qui ne prédit qu'une classe.

4 Collecte des données

4.1 Sources retenues

Nous intégrons trois jeux de données publics, décrits dans le tableau 4. Ils couvrent trois registres de l'arabe : la poésie classique, le dialecte égyptien et un mélange de dialectes.

Tab. 4 : Sources de données retenues.

Source	Contenu	Variété	Lignes brutes	Conditions d'utilisation
Arabic Poem Emotion [11]	Poèmes extraits d'aldiwan.net, fichier CSV de 19,8 Mo	Arabe classique et standard	9 455	Pas de licence ; citation de l'article
ETDA [2]	Tweets collectés vers 2016, fichier CSV de 1,6 Mo	Dialecte égyptien	10 065	Pas de licence ; citation de l'article
SemEval-2018 E-c [10]	Tweets de 2017, archive ZIP de 6,0 Mo (fichiers TSV)	Dialectes variés	4 381	Citation obligatoire ; redistribution interdite

Chaque source a sa propre structure :

- **Poèmes** : colonnes `poem_id`, `poem`, `verses` (nombre de vers) et `emotion`, avec trois valeurs : `sad` (4 063), `love` (3 443) et `joy` (1 943). Les étiquettes reprennent les catégories du site et non une annotation par des lecteurs.
- **ETDA** : colonnes `ID`, `TWEET` et `LABEL`, avec huit classes : `none` (1 550), `anger` (1 444), `joy` (1 281), `sadness` (1 256), `love` (1 220), `fear` (1 207), `sympathy` (1 062) et `surprise` (1 045).
- **SemEval** : trois fichiers TSV (apprentissage 2 278 tweets, développement 585, test 1 518), avec les colonnes `ID`, `Tweet` et onze colonnes binaires, une par émotion. Un tweet peut porter plusieurs émotions ou aucune. Les émotions les plus fréquentes sont la colère (1 723 tweets), la tristesse (1 638) et la joie (1 177) ; la surprise est rare (98).

Le tableau 5 montre un exemple brut par source. La différence de registre est visible : vocalisation complète dans le poème, dialecte et ponctuation libre dans les tweets.

Tab. 5 : Exemples de données brutes.

Source	Étiquette	Texte brut
Poèmes	`love`	الوَردُ في وَجنَتِهِ مُشرِقٌ كَأَنَّما يَشرَبُ مِن مَدمَعي
ETDA	`none`	الاوليبياد الجايه هكون لسه ف الكليه ..
SemEval	`sadness`	ترا انا انسان زيكم تعالوا سولفوا معي احس بالوحدة:(

4.2 Pourquoi intégrer plusieurs sources

Les consignes du module indiquent qu'un seul jeu de données suffit. Nous avons d'abord retenu le jeu de poèmes seul : il était proposé pour ce sujet, déjà étiqueté et accompagné d'un résultat publié. Nous l'avons élargi pour deux raisons :

- Le sujet porte sur les textes arabes en général. Un modèle entraîné uniquement sur de la poésie classique, avec trois émotions, ne sait traiter ni les tweets, ni les dialectes, ni la colère, la peur ou la surprise.
- L'intégration de plusieurs sources donne un contenu réel à l'étape d'intégration de CRISP-DM : harmonisation des étiquettes, détection des doublons entre sources, contrôle des biais liés à la source.

Les trois sources ont été choisies parce qu'elles partagent au moins trois émotions (joie, tristesse, amour) et que les deux sources de tweets apportent la colère, la peur, la surprise et la classe neutre.

4.3 Sources écartées

Le tableau 6 liste les sources étudiées puis écartées.

Tab. 6 : Sources écartées et raisons.

Source	Raison
TUNIZI V2 (100 000 commentaires tunisiens)	Polarité seulement (positif, négatif, neutre), pas d'émotions ; écriture latine (3 lignes sur 100 000 contiennent des caractères arabes). Il aurait fallu l'annoter nous-mêmes.
ArPanEmo [4]	Version publique défectueuse : 2 227 lignes au lieu de 11 128, fichiers d'apprentissage et de test identiques octet par octet, 1 972 lignes ne contenant que « ... ». Seuls 255 messages sont exploitables.
Jeu Mendeley sur la santé mentale (dp338mw226)	Langue non indiquée ; les noms d'étiquettes suggèrent des corpus Twitter anglais fusionnés. Une traduction ajouterait du bruit.
Jeu Mendeley de sentiment arabe (6w9g62xc67)	Polarité seulement ; la description contient un modèle de texte non rempli.
Annotation de nouvelles données	Temps disponible insuffisant pour une annotation fiable à plusieurs annotateurs.

4.4 Outils et procédure de collecte

La collecte est entièrement automatisée. Le fichier `src/config.py` contient l'adresse de chaque source, et un chargeur par source dans `src/sources/` télécharge le fichier, le lit et renvoie un tableau au format commun (identifiant, texte, étiquette d'origine, source, registre, variété) accompagné d'un journal des lignes retirées. Les outils utilisés sont :

- **requests** pour le téléchargement. Le serveur de SemEval refuse l'agent utilisateur par défaut de la bibliothèque (erreur HTTP 406) : le téléchargeur envoie donc un en-tête explicite.
- **zipfile** pour lire les trois fichiers arabes de l'archive SemEval sans l'extraire.
- **pandas** pour la lecture des CSV et TSV et toutes les opérations sur les tableaux.

Le téléchargement est idempotent : un fichier déjà présent dans `data/raw/` n'est pas téléchargé à nouveau. Le dossier `data/` est exclu du dépôt Git, pour respecter l'interdiction de redistribution de SemEval ; toute personne qui clone le dépôt reconstruit les données brutes avec une seule commande.

Nous n'avons pas utilisé de collecte directe sur Twitter. Les outils de moissonnage comme snscrape ne fonctionnent plus depuis la modification de l'API de Twitter en 2023, et des tweets collectés par nous n'auraient de toute façon pas eu d'étiquettes.

5 Compréhension des données

Cette section décrit le corpus final de 15 665 textes, obtenu après la préparation détaillée en section 6, puis les problèmes de qualité rencontrés dans les données brutes. Les deux étapes ont été menées en parallèle : chaque problème de qualité découvert pendant l'exploration a conduit à une règle de préparation.

5.1 Description

Distribution des émotions. La figure 2 et le tableau 7 montrent la répartition des émotions par source. La tristesse est la classe la plus fréquente (3 624 textes) et la surprise la plus rare (1 050). ETDA fournit plus de la moitié du corpus (8 846 textes), les poèmes 4 704 et SemEval 2 115.

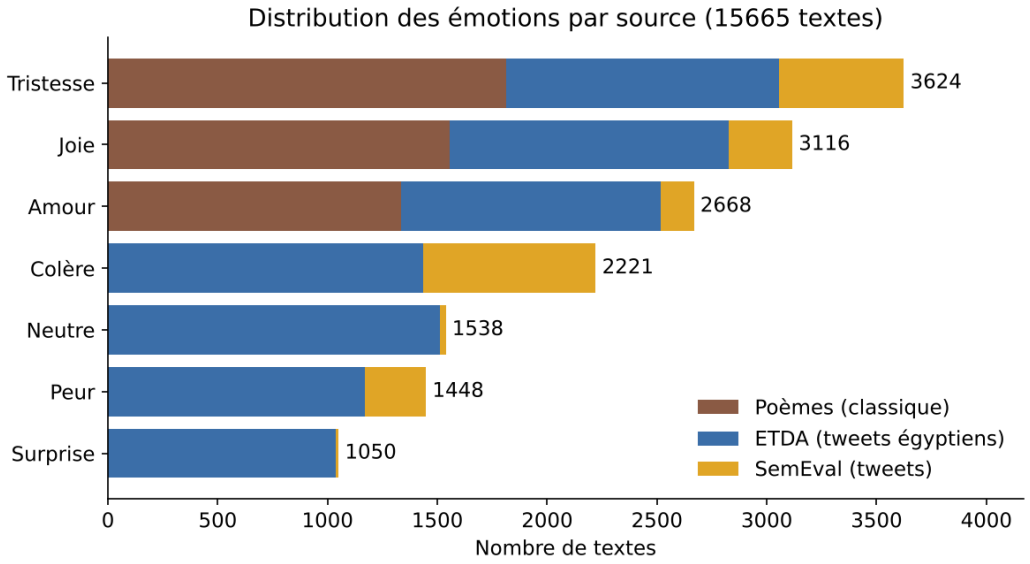


Fig. 2 : Distribution des émotions par source dans le corpus final.

Tab. 7 : Corpus final : nombre de textes par émotion et par source.

Émotion	Poèmes	ETDA	SemEval	Total
Tristesse	1 812	1 245	567	3 624
Joie	1 558	1 268	290	3 116
Amour	1 334	1 182	152	2 668
Colère	0	1 434	787	2 221
Neutre	0	1 513	25	1 538
Peur	0	1 168	280	1 448
Surprise	0	1 036	14	1 050
Total	4 704	8 846	2 115	15 665

Attributs. Chaque texte porte quatorze attributs, décrits en annexe B : l'identifiant, la source, le registre, la variété, l'étiquette harmonisée et l'étiquette d'origine, le texte brut, deux versions normalisées du texte, les émojis extraits, deux comptes de mots et la proportion de diacritiques.

5.2 Exploration

Longueur. Les poèmes et les tweets n'ont pas la même échelle (figure 3, tableau 8). Un poème compte 89 mots en médiane contre 13 pour un tweet d'ETDA, et 22 % des poèmes dépassent 256 mots, ce qui posera problème aux transformeurs limités à 512 jetons. Aucun tweet ne dépasse cette longueur.

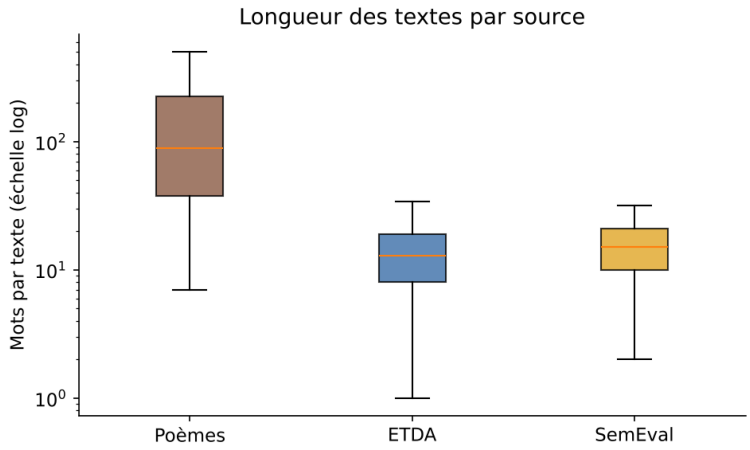


Fig. 3 : Nombre de mots par texte selon la source (échelle logarithmique, valeurs extrêmes masquées).

Diacritiques et émojis. Les signes de vocalisation sont présents (plus de 2 % des caractères) dans 90 % des poèmes, contre 8 % des tweets d'ETDA et 2 % de ceux de SemEval. La proportion médiane de diacritiques dans un poème est de 0,228. À l'inverse, les émojis apparaissent dans 19 % des tweets d'ETDA et 39 % des tweets de SemEval, et dans aucun poème. Le tableau 8 résume ces différences. Chacune de ces caractéristiques suffit presque à identifier la source d'un texte, ce qui renforce le risque de raccourci discuté plus bas.

Tab. 8 : Caractéristiques des textes par source.

	Poèmes	ETDA	SemEval
Mots par texte (médiane)	89	13	15
Mots par texte (90e centile)	438	22	25
Textes de plus de 256 mots	22,1 %	0 %	0 %
Textes vocalisés	89,9 %	7,7 %	1,6 %
Textes avec émojis	0 %	19,0 %	38,7 %

Vocabulaire. Le corpus normalisé contient 159 246 formes distinctes. Cette taille vient surtout des clitiques attachés : و (et), ب (avec), ال (l'article) se collent au mot suivant, de sorte que الحب, بالحب et والحب sont trois formes différentes. La suppression des mots vides retire 22,8 % des occurrences. La phase 2 devra réduire ce vocabulaire par segmentation ou racinisation.

Mots caractéristiques. Pour chaque émotion, nous avons calculé le log-ratio entre la fréquence documentaire d'un mot dans cette émotion et sa fréquence dans les autres, pour les mots présents dans au moins 30 textes (figure 4). Le résultat se lit en deux groupes :

- La tristesse, la peur et en partie l'amour ont des mots réellement émotionnels : الحزن (la tristesse), بالدموع (avec les larmes), خايفه (j'ai peur), مرعب (terrifiant), عشق (passion), احبك (je t'aime).

- La colère, la surprise et la classe neutre sont dominées par d'autres indices. Pour la colère : des noms propres et des entités politiques (ايران, داعش, بشار). Pour la surprise : des marqueurs du dialecte égyptien (ازاي, دا, كدا). Pour la classe neutre : le vocabulaire des Jeux olympiques (ريو, البرازيل, ميداليات).

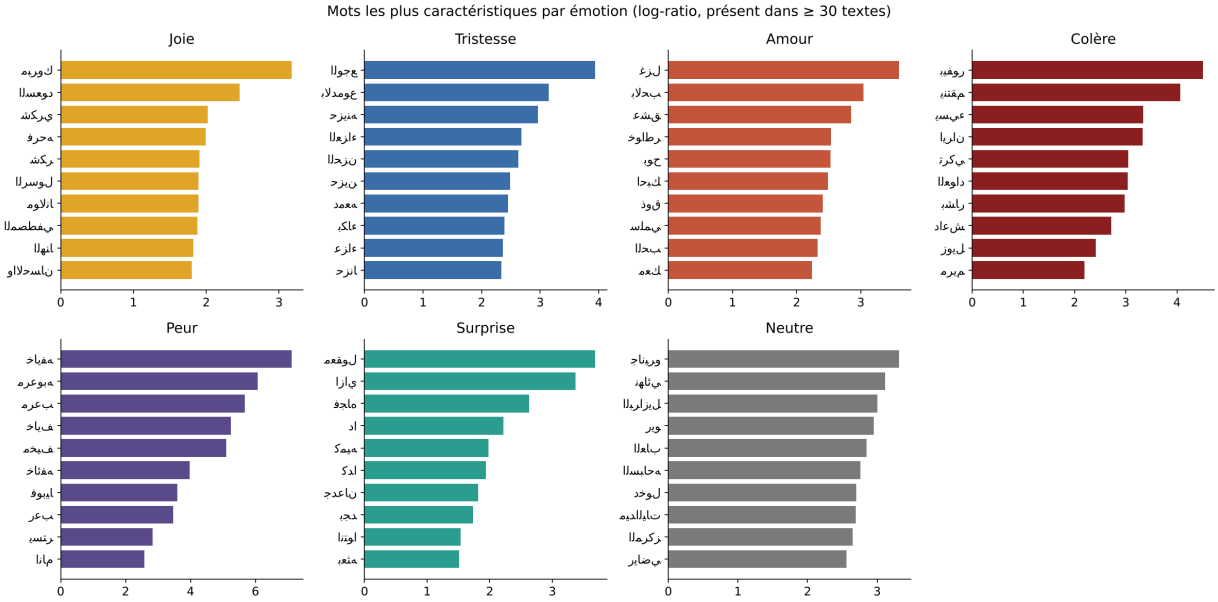


Fig. 4 : Les dix mots les plus caractéristiques de chaque émotion (log-ratio des fréquences documentaires).

Une analyse limitée aux poèmes, menée avant l'intégration, montre aussi que leurs étiquettes suivent les genres de la poésie classique : la tristesse correspond à l'élégie (قبر, العزاء, المنون), l'amour au ghazal, avec les prénoms de la bien-aimée (ليلى, هند, سلمى) et le vin (خمر), et la joie au panégyrique et à la louange religieuse (النبي, الأمير, المصطفى). Dans cette même analyse, la densité de diacritiques était identique d'une émotion à l'autre (entre 22 et 23 %) : les supprimer ne fait perdre aucune information sur la classe.

5.3 Qualité des données

Problèmes techniques. Les fichiers bruts présentent plusieurs défauts, tous détectés et comptés par le code :

- **Lignes cassées dans les poèmes.** Trois poèmes dépassent 32 767 octets, la longueur maximale d'une ligne dans le fichier source. Leur fin déborde sur une ligne supplémentaire, où la colonne d'étiquette contient alors une époque ou un pays (تونس, مصر, العصر العباسي). Ces 6 lignes sont inutilisables. La coupure tombe au milieu de caractères codés sur plusieurs octets, ce qui produit 3 séquences UTF-8 invalides.
- **Doublons** : 15 poèmes et 36 tweets d'ETDA apparaissent deux fois avec la même étiquette.
- **Étiquettes contradictoires** : 16 lignes d'ETDA correspondent à des textes identiques portant des étiquettes différentes.
- **Valeurs manquantes** : un tweet d'ETDA a un texte vide.
- **Tweets tronqués** : certains tweets d'ETDA s'arrêtent au milieu d'un mot dans le fichier d'origine. Ils sont conservés, car le début du texte reste exploitable.
- **Textes réduits aux émojis** : 3 tweets d'ETDA deviennent vides une fois les émojis retirés.

Sémantique des étiquettes. Les trois sources n'ont pas été étiquetées de la même façon. Les étiquettes des poèmes sont les catégories d'un site web, et « triste » y réunit tristesse et élégie. Celles de SemEval résultent d'un vote de plusieurs annotateurs, avec un seuil bas (plus de 25 % des votes) qui produit beaucoup de tweets à plusieurs émotions : 2 095 des 4 381 tweets portent au moins deux des émotions retenues. ETDA contient une classe « sympathy » sans équivalent ailleurs. Ces différences sont traitées à l'étape d'intégration (section 6.3).

Fuites d'information. L'exploration a révélé plusieurs indices qu'un modèle pourrait utiliser pour prédire l'étiquette sans comprendre l'émotion :

- **Source.** La colère, la peur, la surprise et la classe neutre ne viennent que des tweets ; 99 % de la surprise et 98 % de la classe neutre viennent d'ETDA (figure 5, section 6.3). Un modèle peut apprendre « un texte qui ressemble à un poème exprime la tristesse, l'amour ou la joie ».
- **Thème.** ETDA a été collecté pendant les Jeux olympiques de Rio. Le tableau 9 donne la part des tweets d'ETDA qui en parlent, par émotion : presque tous les tweets neutres, aucun tweet d'amour.
- **Entités nommées et dialecte**, comme le montrent les mots caractéristiques de la colère et de la surprise.
- **Hashtags.** 29,5 % des tweets de SemEval contiennent un hashtag, et certains nomment directement l'émotion : #حزن (tristesse) apparaît dans 11 tweets, tous tristes ; #رعب (terreur) dans 7 tweets, tous de peur ; #سعادة (bonheur) dans 9 tweets, dont 8 de joie.

Tab. 9 : Part des tweets d'ETDA liés aux Jeux olympiques de 2016, par émotion.

	Neutre	Joie	Surprise	Tristesse	Colère	Peur	Amour
Part	98,5 %	30,9 %	29,0 %	24,8 %	9,8 %	2,2 %	0 %

Ces fuites ne peuvent pas toutes être supprimées sans perdre l'essentiel des données. Nous les réduisons quand c'est possible (plafond de poèmes) et nous les mesurerons en phase 3 pour savoir quelle part des performances elles expliquent.

6 Préparation des données

La préparation est réalisée par le module `src/integrate.py`, qui enchaîne cinq étapes : chargement et nettoyage par source, harmonisation des étiquettes, normalisation et dédoublonnage, plafonnement des poèmes, puis calcul des attributs dérivés. Chaque étape enregistre ses comptes dans `reports/quality_report.json`.

6.1 Nettoyage

Le nettoyage par source traite les problèmes listés en section 5.3 :

- les lignes cassées des poèmes sont repérées par une étiquette hors des trois valeurs attendues ou un nombre de vers non numérique, puis retirées ;
- les textes vides sont retirés ;
- pour les doublons exacts, une seule copie est conservée ; pour un texte présent avec des étiquettes contradictoires, toutes les copies sont retirées, car aucune ne peut être préférée.

Tab. 10 : Nettoyage par source.

Source	Lignes brutes	Retraits	Conservées
Poèmes	9 455	6 lignes cassées, 15 doublons	9 434
ETDA	10 065	1 texte vide, 36 doublons, 16 étiquettes contradictoires	10 012
SemEval	4 381	2 095 tweets à plusieurs émotions (mis de côté), 166 tweets portant uniquement des émotions non retenues	2 120
Total	23 901		21 566

6.2 Transformation

Normalisation du texte. L'arabe s'écrit de plusieurs façons pour un même mot : avec ou sans vocalisation, avec différentes formes de l'alif, avec des lettres étirées. Le module `src/arabic.py` applique les transformations du tableau 11, dans cet ordre.

Tab. 11 : Étapes de normalisation.

Étape	Justification
Normalisation Unicode NFKC	Ramène les formes de présentation arabes (ﻳ, ﺃ) aux lettres de base.
Suppression des caractères invisibles	Les marques de direction et espaces de largeur nulle séparent des mots identiques.
Suppression des URL et des mentions ; # et _ remplacés par des espaces	Les liens et les noms d'utilisateur ne portent pas d'émotion ; le texte des hashtags est conservé.
Suppression des diacritiques et de la tatweel (ـ)	La vocalisation sépare les poèmes des tweets sans informer sur l'émotion (section 5).
Unification de أ إ آ ٱ vers ا, de ى vers ي, de ة vers ه	Ces lettres sont employées de façon incohérente, surtout dans les tweets.
Suppression des caractères non arabes	Les chiffres, lettres latines et émojis sont retirés du texte (les émojis sont conservés dans une colonne à part).
Réduction des lettres répétées 3 fois ou plus	L'allongement expressif (جداااا) n'existe pas dans l'orthographe standard.

L'unification de ة (tā' marbūṭa) vers ه réduit la dispersion du vocabulaire mais confond deux lettres distinctes ; elle peut être désactivée par un paramètre de `src/config.py`. L'exemple ci-dessous, tiré d'ETDA (étiquette amour), montre l'effet de la normalisation sur un tweet contenant de la tatweel, des lettres étirées et cinq émojis :

Texte brut	صعب فرقاااااهـ صعب انسـاااااه [émojis] مساء الشوق [émoji] قبل يومين [émoji] عراقي
`text_norm`	صعب فرقاه صعب انساه مساء الشوق قبل يومين عراقي
`text_nostop`	صعب فرقاه صعب انساه الشوق يومين عراقي

Mots vides. Nous partons de la liste arabe de NLTK [6], normalisée avec les mêmes règles que les textes, soit 617 entrées. Les négations en sont retirées et donc conservées dans les textes (لا, لم, لن, ليس, ليست, ما, غير, بلا), car elles inversent le sens émotionnel d'une phrase. Deux limites sont connues : ما est souvent un pronom relatif en poésie, et la liste de NLTK vise l'arabe standard et oublie certains mots outils classiques.

Deux versions du texte. Le corpus conserve `text_norm`, le texte normalisé complet, destiné aux transformeurs qui ont besoin de la phrase entière, et `text_nostop`, sans mots vides, destiné aux représentations de type TF-IDF.

6.3 Intégration

Harmonisation des étiquettes. Nous retenons sept émotions : celles qu'au moins deux sources peuvent alimenter, plus la classe neutre. Le tableau 12 donne la correspondance entre les étiquettes d'origine et les étiquettes cibles.

Tab. 12 : Correspondance des étiquettes.

Cible	Poèmes	ETDA	SemEval
Joie	`joy`	`joy`	`joy`
Tristesse	`sad`	`sadness`	`sadness`
Amour	`love`	`love`	`love`
Colère		`anger`	`anger`
Peur		`fear`	`fear`
Surprise		`surprise`	`surprise`
Neutre		`none`	aucune émotion cochée
Retirée		`sympathy`	`optimism`, `pessimism`, `anticipation`, `trust`, `disgust`

La classe « sympathy » d'ETDA. Elle regroupe 1 046 tweets de solidarité, de prières, d'encouragements et de condoléances adressés à d'autres : قلوبنا معكم (nos cœurs sont avec vous), الله ينصركم (que Dieu vous donne la victoire), الله يرحمه (que Dieu ait son âme). Elle décrit une attitude envers autrui, et non l'émotion de l'auteur. La fusionner avec la tristesse apprendrait au modèle que l'encouragement est triste ; la garder comme huitième classe ajouterait une classe présente dans une seule source. Nous l'avons retirée.

SemEval en mono-étiquette. Les poèmes et ETDA ont une seule étiquette par texte, SemEval plusieurs. Pour garder un format unique, nous ne conservons que les tweets qui portent exactement une des six émotions retenues (2 095) et les tweets sans aucune émotion, étiquetés neutres (25). Les 2 095 tweets portant au moins deux émotions retenues sont mis de côté dans `semeval_mixed.csv` ; ils serviront de jeu de test qualitatif en phase 3. Les combinaisons les plus fréquentes y sont joie, amour et optimisme (477 tweets), et colère et tristesse (202). Ce choix a un coût : les tweets conservés sont les moins ambigus, et les scores sur SemEval seront donc optimistes. Le dégoût n'a pas été fusionné avec la colère, bien qu'il en soit proche : il apparaît avec la colère dans 761 de ses 855 tweets, et sa fusion n'aurait presque rien ajouté.

Doublons entre sources. Après normalisation, des textes différents dans les fichiers bruts deviennent identiques. Nous appliquons la même règle qu'au nettoyage : 115 doublons de même étiquette sont retirés, ainsi que 17 lignes aux étiquettes contradictoires. Deux groupes de doublons traversent deux sources.

Plafonnement des poèmes. Après harmonisation, les poèmes représentaient plus de la moitié des trois émotions qu'ils couvrent (56 % de la joie, 69 % de la tristesse et 72 % de l'amour), ce qui aggravait le raccourci lié à la source. Nous limitons la part des poèmes à 50 % dans chaque émotion. Pour une émotion comptant n tweets, on garde au plus $n \times s/(1-s)$ poèmes, avec $s = 0{,}5$, soit autant de poèmes que de tweets ; les poèmes sont tirés au hasard avec une graine fixe (42). Les 4 720 poèmes retirés (2 237 de tristesse, 2 101 d'amour, 382 de joie) sont conservés

dans `poems_reserve.csv` et pourront servir de test supplémentaire. La figure 5 montre la part de chaque source dans chaque émotion après plafonnement.

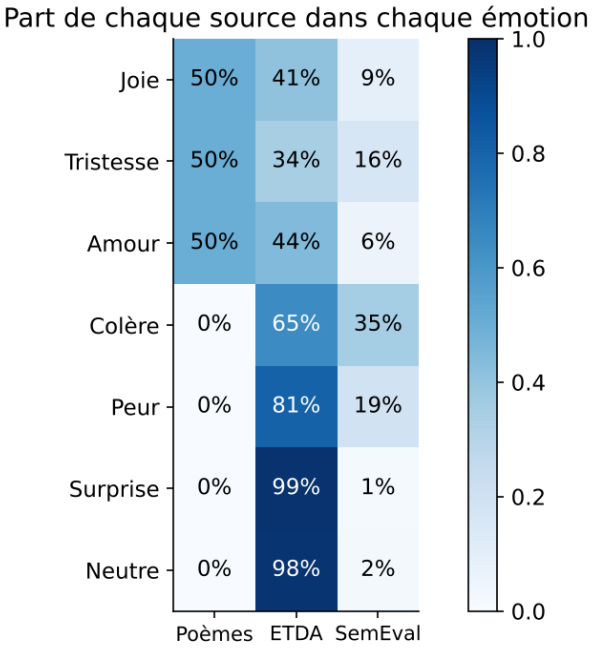


Fig. 5 : Part de chaque source dans chaque émotion du corpus final.

Nous avons écarté deux autres solutions : découper les poèmes en extraits de la taille d'un tweet (l'étiquette d'un poème entier ne vaut pas pour chacun de ses vers) et annoter des poèmes de colère ou de peur (pas le temps).

6.4 Enrichissement

L'enrichissement consiste à ajouter aux données des attributs qu'elles ne contenaient pas. Nous avons ajouté sept attributs, présents pour chaque texte (tableau 13).

Tab. 13 : Attributs ajoutés aux données.

Attribut	Contenu	Usage prévu
`register`	Poésie classique ou tweet	Axe 3 du sujet, scores par registre
`variety`	Arabe classique, égyptien, dialectes variés	Axe 3, choix du modèle pré-entraîné
`emojis`	Émojis extraits du texte brut	Variable candidate en phase 2
`diacritic_ratio`	Part de diacritiques dans le texte brut	Contrôle du raccourci lié à la source
`n_words`, `n_words_nostop`	Nombre de mots avant et après retrait des mots vides	Choix de la troncature des poèmes longs
`uid`	Identifiant unique `source:id`	Traçabilité vers le fichier d'origine

Les émojis portent un signal émotionnel réel, mais ils sont absents des poèmes : les utiliser renforcerait le raccourci lié à la source. Ils sont donc extraits mais pas encore utilisés ; la phase 2 comparera un modèle avec et sans eux. Deux ensembles annexes complètent le corpus : la réserve de poèmes et les tweets SemEval à plusieurs émotions.

6.5 Bilan de la préparation

Le tableau 14 et la figure 6 résument le passage des 23 901 lignes brutes aux 15 665 textes du corpus final.

Tab. 14 : Nombre de lignes après chaque étape.

Étape	Lignes
Lignes brutes, trois sources	23 901
Après nettoyage par source	21 566
Après harmonisation des étiquettes	20 520
Après normalisation et dédoublonnage	20 385
Après plafonnement des poèmes (corpus final)	15 665

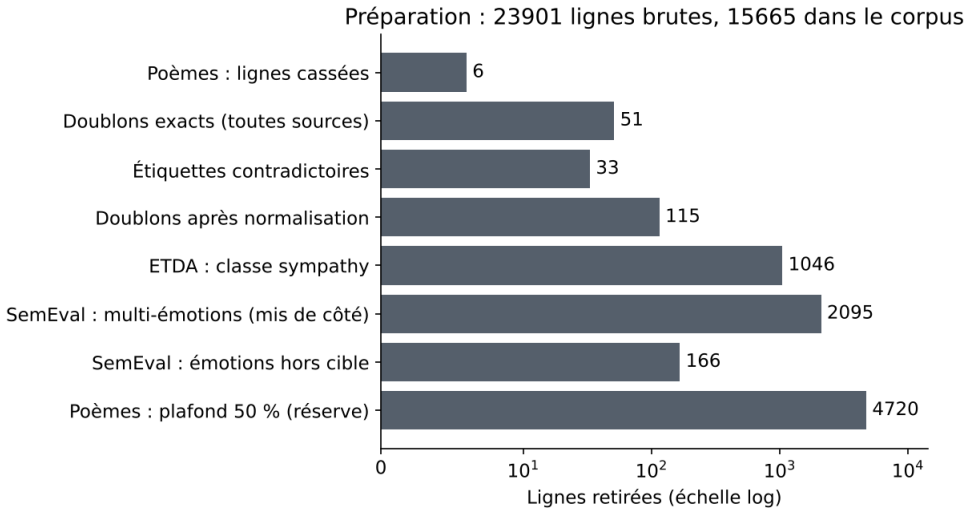


Fig. 6 : Lignes retirées par motif (échelle logarithmique).

Le pipeline produit trois fichiers dans `data/processed/` : `corpus.csv` (15 665 textes), `poems_reserve.csv` (4 720 poèmes) et `semeval_mixed.csv` (2 095 tweets).

7 Limites et suite du projet

7.1 Limites connues

- **Confusion entre source et émotion.** Le plafonnement réduit le déséquilibre mais ne crée pas de poèmes de colère, de peur ou de surprise. Une partie des performances futures pourra venir de la reconnaissance du registre ; la phase 3 la mesurera.
- **Biais de sélection de SemEval.** Seuls les tweets à une seule émotion sont conservés : ce sont les plus faciles.
- **Biais thématiques d'ETDA.** La classe neutre est presque entièrement composée de tweets sportifs, et la colère de tweets politiques.
- **Couverture.** Le corpus ne contient ni dialecte maghrébin (en particulier tunisien), ni texte journalistique, ni prose littéraire moderne. Les performances sur ces registres sont inconnues.
- **Étiquettes de genre.** Les étiquettes des poèmes reflètent des genres (élégie, ghazal, panégyrique) plus que l'émotion de chaque vers.

7.2 Décisions reportées à la phase 2

- **Découpage** : apprentissage, validation et test (70/15/15), stratifiés par émotion et par source, avec une graine fixe. La réserve de poèmes et les tweets à plusieurs émotions restent hors de l'apprentissage.
- **Hashtags** : tester la suppression complète des mots issus de hashtags, y compris les mots de genre d'ETDA dont le # a été retiré par les auteurs (بوح, الرومنسيه).
- **Jeux olympiques** : marquer les tweets concernés pour entraîner un modèle sans eux.
- **Poèmes longs** : 22 % dépassent 256 mots ; comparer la troncature, la combinaison début et fin, et le découpage en morceaux dont on moyenne les prédictions.
- **Morphologie** : comparer la racinisation ISRI de NLTK et la segmentation des clitiques (Farasa ou CAMeL Tools) sur la taille du vocabulaire et les performances.
- **Émojis** : comparer un modèle avec et sans la colonne `emojis`.

Références

[1] Muhammad Abdul-Mageed, AbdelRahim Elmadany, and El Moatez Billah Nagoudi. ARBERT & MARBERT : Deep bidirectional transformers for Arabic. In *Proceedings of ACL-IJCNLP 2021*, pages 7088–7105, 2021.

[2] Amr Al-Khatib and Samhaa R. El-Beltagy. Emotional tone detection in Arabic tweets. In *Computational Linguistics and Intelligent Text Processing (CICLing 2017)*, Lecture Notes in Computer Science. Springer, 2017. doi : 10.1007/978-3-319-77116-8_8.

[3] Reem Hamed Aljuhani, Areej Alshutayri, and Shahd Alahdal. Arabic speech emotion recognition from Saudi dialect corpus. *IEEE Access*, 9, 2021. doi : 10.1109/ACCESS.2021.3110992.

[4] Maha Jarallah Althobaiti. ArPanEmo : An open-source dataset for fine-grained emotion recognition in Arabic online content during COVID-19 pandemic. *Data in Brief*, 51:109745, 2023.

[5] Wissam Antoun, Fady Baly, and Hazem Hajj. AraBERT : Transformer-based model for Arabic language understanding. In *Proceedings of the 4th Workshop on Open-Source Arabic Corpora and Processing Tools (OSACT)*, pages 9–15, 2020.

[6] Steven Bird, Ewan Klein, and Edward Loper. *Natural Language Processing with Python*. O'Reilly, 2009.

[7] Pete Chapman, Julian Clinton, Randy Kerber, Thomas Khabaza, Thomas Reinartz, Colin Shearer, and Rüdiger Wirth. CRISP-DM 1.0: Step-by-step data mining guide. Technical report, SPSS, 2000.

[8] Ziad Doughan, Sari Itani, and Samir Itani. ArabSis : Arabic corpus sentiment analysis. *IEEE Access*, 2025. doi : 10.1109/ACCESS.2025.3567755.

[9] Go Inoue, Bashar Alhafni, Nurpeiis Baimukan, Houda Bouamor, and Nizar Habash. The interplay of variant, size, and task type in Arabic pre-trained language models. In *Proceedings of the Sixth Arabic Natural Language Processing Workshop (WANLP)*, 2021.

[10] Saif Mohammad, Felipe Bravo-Marquez, Mohammad Salameh, and Svetlana Kiritchenko. SemEval-2018 task 1: Affect in tweets. In *Proceedings of the 12th International Workshop on Semantic Evaluation*, pages 1–17, 2018. doi : 10.18653/v1/S18-1001.

[11] Sakib Shahriar, Noora Al Roken, and Imran Zualkernan. Classification of Arabic poetry emotions using deep learning. *Computers*, 12(5) :89, 2023. doi : 10.3390/computers12050089.

A Organisation du code et reproduction

```
requirements.txt          dépendances Python
src/
  config.py               adresses des sources, correspondance des étiquettes,
                          plafond des poèmes, graine, option ta marbuta
  arabic.py               normalisation, extraction des émojis, mots vides
  integrate.py            pipeline de préparation
  eda.py                  figures et statistiques d'exploration
  sources/
    common.py             téléchargement, doublons et contradictions
    poems.py              chargeur des poèmes (lignes cassées)
    etda.py               chargeur d'ETDA
    semeval.py            chargeur de SemEval (filtre mono-étiquette)
data/                     non versionné
  raw/                    fichiers téléchargés
  processed/              corpus.csv, poems_reserve.csv, semeval_mixed.csv
reports/
  quality_report.json     comptes de chaque étape de préparation
  eda_stats.json          statistiques d'exploration
  figures/                fig01 à fig05
```

Reproduction complète (Python 3.10 ou plus récent) :

```
pip install -r requirements.txt
python -m src.integrate   # télécharge, nettoie, harmonise, écrit data/processed/
python -m src.eda         # écrit reports/figures/ et reports/eda_stats.json
```

La graine aléatoire (42) fixe le tirage des poèmes conservés et l'ordre du corpus : deux exécutions donnent le même résultat.

B Schéma du corpus

Tab. 15 : Colonnes de `data/processed/corpus.csv`.

Colonne	Contenu
`uid`	Identifiant unique `source:source_id`
`source`	`poems`, `etda` ou `semeval`
`source_id`	Identifiant dans le fichier d'origine
`register`	`classical_poetry` ou `tweet`
`variety`	`classical_msa`, `egyptian` ou `mixed_dialects`
`label`	Étiquette harmonisée (7 valeurs)
`label_raw`	Étiquette d'origine
`text_raw`	Texte d'origine
`text_norm`	Texte normalisé, pour les transformeurs
`text_nostop`	Texte normalisé sans mots vides (négations conservées), pour TF-IDF ; vide pour 7 textes
`emojis`	Émojis extraits du texte brut
`n_words`, `n_words_nostop`	Nombre de mots
`diacritic_ratio`	Part des caractères du texte brut qui sont des diacritiques